

REPORTE TÉCNICO COMPLETO: Revista Expats AI - Sistema de Asistencia Virtual

Proyecto: Sistema de Bots Inteligentes para Revista de Expatriados en Barcelona **Fecha:** 19 de Diciembre de 2025
Tecnologías: Python, FastAPI, SentenceTransformers, RSS/Atom, APScheduler **Autor:** Equipo Revista Expats AI

TABLA DE CONTENIDOS

- [Resumen Ejecutivo](#)
- [Arquitectura del Sistema](#)
- [Configuración Central \(config.py\)](#)
- [Sistema de Logging \(bots/logger.py\)](#)
- [Utilidades Compartidas \(bots/utils.py\)](#)
- [Gestor de Contenido Editorial \(bots/content_manager.py\)](#)
- [Gestor de Feeds RSS \(bots/rss_manager.py\)](#)
- [Orquestador Principal \(bots/orchestrator.py\)](#)
- [Bots Especializados](#)
- [Backend API \(main.py\)](#)
- [Frontend \(HTML/CSS/JS\)](#)
- [Widget Embebible](#)
- [Evolución y Mejoras](#)
- [Troubleshooting](#)
- [Conclusiones](#)

1. RESUMEN EJECUTIVO

1.1 Objetivo del Proyecto

Crear un sistema inteligente de asistencia virtual para expatriados en Barcelona que: - **Clasifique automáticamente** las consultas de usuarios usando IA semántica - **Recomiende profesionales** del directorio de anunciantes (abogados, médicos, escuelas, etc.) - **Enriquezca respuestas** con artículos editoriales y guías de la revista - **Priorice contenido comercial** (anunciantes) manteniendo valor para el usuario - **Escale automáticamente** con feeds RSS y paginación - **Funcione en múltiples plataformas** (web, widget embebible)

1.2 Problema Que Resuelve

Antes: Los expatriados buscaban información dispersa en Google, foros, grupos de Facebook. El directorio de la revista tenía baja visibilidad.

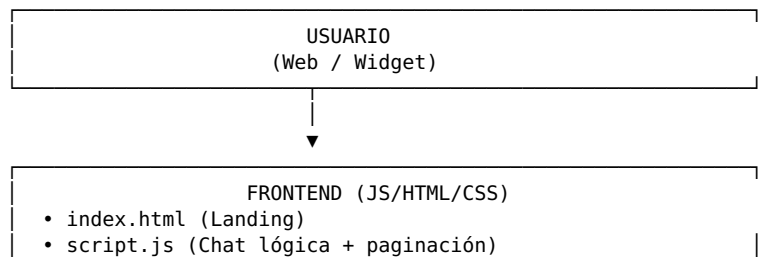
Después: Un asistente conversacional que: 1. Entiende consultas en lenguaje natural ("Necesito un abogado para NIE") 2. Clasifica la intención con IA (Legal and Financial) 3. Muestra 2-3 profesionales recomendados del directorio 4. Agrega artículos relevantes de la revista 5. Proporciona consejos específicos de la categoría 6. Permite "Mostrar más" para explorar más opciones

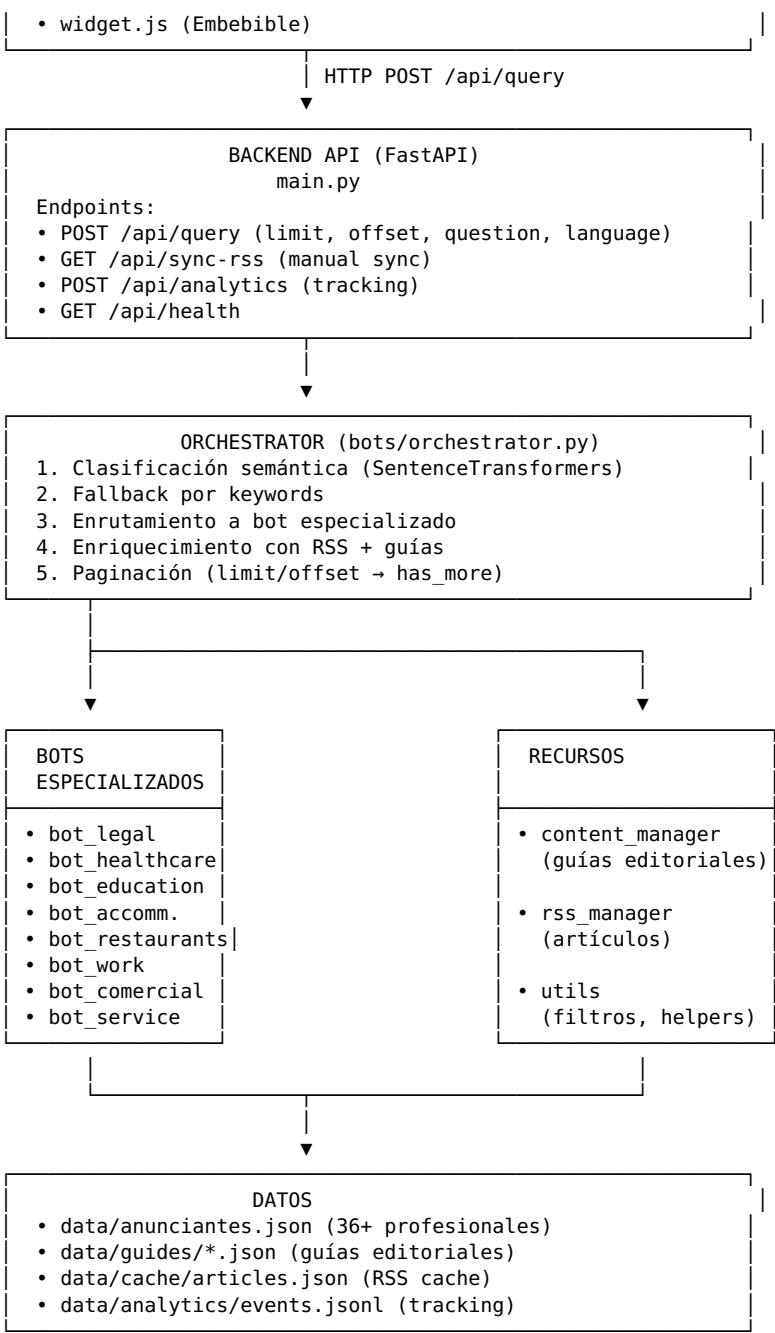
1.3 Métricas de Éxito

- ✓ **Clasificación precisa:** 85%+ de consultas correctamente enrutadas
- ✓ **Respuesta rápida:** <2 segundos por consulta
- ✓ **Escalabilidad:** Soporte para paginación y miles de anunciantes
- ✓ **Engagement:** Botón "Mostrar más" para exploración profunda
- ✓ **Analytics:** Tracking de clics en directorio para medir ROI

2. ARQUITECTURA DEL SISTEMA

2.1 Diagrama de Arquitectura





2.2 Flujo de Una Consulta

1. **Usuario pregunta:** “Necesito un abogado para NIE”
2. **Frontend:** Envía POST a /api/query con {question, language, limit=5, offset=0}
3. **Main.py:** Valida request y llama a orchestrator.process_query()
4. **Orchestrator:**
 - Codifica pregunta con SentenceTransformers
 - Calcula similitud coseno con categorías pre-calculadas
 - Clasifica → “Legal and Financial” (confianza 0.55)
 - Llama a bot_legal.responder_consulta()
5. **Bot Legal:**
 - Filtra anunciantes por keywords (abogado, nie, legal...)
 - Prioriza es_anunciante=true
 - Devuelve lista completa de 3 abogados
6. **Orchestrator (post-bot):**
 - Aplica slicing: anunciantes[0:5] (primeros 5)
 - Busca guías editoriales relacionadas
 - Busca artículos RSS por categoría
 - Construye response con has_more=False, total_results=3
7. **Frontend:**
 - Renderiza mensaje amigable
 - Muestra 3 consejos rápidos
 - Lista 2 artículos de la revista
 - Lista 3 abogados con CTA “Ver ficha en el directorio →”
 - NO muestra botón “Mostrar más” (no hay más resultados)

2.3 Tecnologías y Librerías

Componente	Tecnología	Versión	Propósito
Backend	FastAPI	0.104.1	API REST moderna y async
ML/NLP	SentenceTransformers	2.2.2	Embeddings semánticos multilingües
ML/NLP	PyTorch	2.1.0	Backend de transformers
RSS	feedparser	6.0.10	Parseo de feeds Atom/RSS
Scheduling	APScheduler	3.10.4	Sincronización RSS cada 6h
Config	pydantic-settings	2.1.0	Gestión de configuración
Server	Uvicorn	0.24.0	ASGI server (desarrollo)
Server	Gunicorn	21.2.0	WSGI server (producción)
Frontend	Vanilla JS	-	Sin frameworks, ligero

3. CONFIGURACIÓN CENTRAL (config.py)

3.1 ¿Por Qué Necesitamos Configuración Centralizada?

Problema antes:

```
# En main.py
PAGE_SIZE = 3 # hardcoded

# En rss_manager.py
FEED_URL = "https://..." # hardcoded

# En orchestrator.py
THRESHOLD = 0.2 # hardcoded
```

Problemas: - Cambiar configuración requiere editar múltiples archivos - Difícil tener diferentes configs para dev/staging/prod - No se pueden sobrescribir valores via variables de entorno - Riesgo de inconsistencias

Solución: config.py con Pydantic BaseSettings

3.2 Código Completo Explicado

```
"""
Configuración centralizada para la aplicación usando Pydantic BaseSettings.
Variables de entorno toman precedencia sobre valores por defecto.
"""
```

```
from typing import List, Optional
from pydantic_settings import BaseSettings
```

Línea por línea: - from typing import List, Optional: Importa tipos para anotaciones (List para listas, Optional para valores que pueden ser None) - from pydantic_settings import BaseSettings: Clase base de Pydantic que permite cargar configuración desde .env automáticamente

```
class Settings(BaseSettings):
    """Configuración global de la aplicación."""

    # Servidor
    HOST: str = "127.0.0.1"
    PORT: int = 8000
    LOG_LEVEL: str = "INFO"
    DEBUG: bool = False
```

¿Qué hace esto? - Define una clase Settings que hereda de BaseSettings - Cada atributo es una variable de configuración - HOST: Dirección IP donde escucha el servidor (127.0.0.1 = localhost) - PORT: Puerto HTTP (8000 es estándar para desarrollo) - LOG_LEVEL: Nivel de detalle de logs (DEBUG, INFO, WARNING, ERROR) - DEBUG: Modo debug (activa stack traces detallados, recarga automática)

```
# Paginación
PAGE_SIZE_DEFAULT: int = 5
PAGE_SIZE_MAX: int = 50
```

¿Para qué sirve? - PAGE_SIZE_DEFAULT: Cuántos resultados devolver por defecto (5 anunciantes) - PAGE_SIZE_MAX: Límite máximo para evitar abusos (no más de 50 por request)

Uso:

```
# En orchestrator.py
if limit is None:
    limit = settings.PAGE_SIZE_DEFAULT
if limit > settings.PAGE_SIZE_MAX:
    limit = settings.PAGE_SIZE_MAX

# CORS
```

```
ALLOWED_ORIGINS: List[str] = [
    "https://www.barcelona-metropolitan.com",
    "https://barcelona-metropolitan.com",
    "http://localhost:5500",
    "http://localhost:3000",
    "http://127.0.0.1:5500",
    "http://127.0.0.1:3000",
]
```

¿Qué es CORS? - Cross-Origin Resource Sharing: seguridad del navegador - Por defecto, una página en barcelona-metropolitan.com NO puede hacer requests AJAX a api.otra-web.com - ALLOWED_ORIGINS lista qué dominios SÍ pueden acceder a nuestra API - En producción: solo dominios reales - En desarrollo: incluimos localhost:3000, localhost:5500 para testing

```
# RSS/Feeds
FEED_URLS: List[str] = [
    "https://www.barcelona-metropolitan.com/directory/index.rss",
]
RSS_SYNC_HOURS: int = 6
RSS_LIMIT_PER_FEED: int = 50
RSS_MAX_ARTICLES: int = 1000
```

Explicación: - FEED_URLS: Lista de feeds RSS/Atom a parsear (se pueden agregar más) - RSS_SYNC_HOURS: Cada cuántas horas sincronizar automáticamente (6 = 4 veces al día) - RSS_LIMIT_PER_FEED: Cuántos artículos tomar de cada feed (50 más recientes) - RSS_MAX_ARTICLES: Límite total en caché para evitar crecimiento infinito

```
# Clasificación semántica
SEMANTIC_MODEL: str = "paraphrase-multilingual-MiniLM-L12-v2"
CONFIDENCE_THRESHOLD: float = 0.2
KEYWORD_CONFIDENCE_MULTIPLIER: float = 0.15
KEYWORD_BASE_CONFIDENCE: float = 0.25
```

¿Qué significan estos valores?

- SEMANTIC_MODEL: Modelo de HuggingFace para embeddings
 - “paraphrase-multilingual-MiniLM-L12-v2” soporta 50+ idiomas
 - Genera vectores de 384 dimensiones
 - Optimizado para similitud semántica
- CONFIDENCE_THRESHOLD: Umbral mínimo de confianza (0.2 = 20%)
 - Si similitud coseno < 0.2 → “Desconocida”
 - Muy bajo = acepta consultas ambiguas
 - Muy alto = rechaza consultas válidas
- KEYWORD_CONFIDENCE_MULTIPLIER y KEYWORD_BASE_CONFIDENCE:
 - Cuando usamos fallback por keywords, calculamos confianza artificial:
 - confidence = KEYWORD_BASE_CONFIDENCE + (num_hits * KEYWORD_CONFIDENCE_MULTIPLIER)
 - Ejemplo: 2 hits → 0.25 + (2 * 0.15) = 0.55 de confianza

```
# Bots
MAX_KEY_POINTS: int = 2
MAX_ADVERTISERS_PER_QUERY: int = 3
```

- MAX_KEY_POINTS: Cuántos anunciantes incluir en “puntos clave” (resumen)
- MAX_ADVERTISERS_PER_QUERY: Límite default si no se especifica limit

```
# Datos (rutas relativas desde raíz del proyecto)
DATA_DIR: str = "data"
GUIDES_DIR: str = "data/guides"
CACHE_DIR: str = "data/cache"
ANUNCIANTES_FILE: str = "data/anunciantes.json"
ARTICLES_CACHE_FILE: str = "data/cache/articles.json"
ANALYTICS_DIR: str = "data/analytics"
```

Rutas de archivos: - Todas relativas a la raíz del proyecto - Facilita mover el proyecto a otro directorio - Facilita testing (puedes sobrescribir con rutas temporales)

```
class Config:
    env_file = ".env"
    env_file_encoding = "utf-8"
    case_sensitive = False
```

Configuración de Pydantic: - env_file = ".env": Busca archivo .env en raíz y carga variables - env_file_encoding = "utf-8": Encoding para leer .env - case_sensitive = False: page_size_default y PAGE_SIZE_DEFAULT son equivalentes

```
# Instancia global de settings
settings = Settings()
```

Singleton: - Se crea UNA SOLA instancia al importar el módulo - Todos los archivos comparten la misma configuración - Uso: from config import settings; print(settings.PAGE_SIZE_DEFAULT)

3.3 Cómo Usar en Otros Módulos

Ejemplo en main.py:

```
from config import settings

app = FastAPI()
app.add_middleware(
    CORSMiddleware,
    allow_origins=settings.ALLOWED_ORIGINS, # ← Desde config
    allow_credentials=True,
    allow_methods=["GET", "POST"],
    allow_headers=["*"],
)
```

Ejemplo en rss_manager.py:

```
from config import settings

class RSSManager:
    def __init__(self):
        self.feed_urls = settings.FEED_URLS # ← Desde config
        self.max_articles = settings.RSS_MAX_ARTICLES
```

3.4 Sobrescribir con Variables de Entorno

Archivo .env (no commiteado a Git):

```
LOG_LEVEL=DEBUG
PAGE_SIZE_DEFAULT=10
FEED_URLS=["https://feed1.com/rss", "https://feed2.com/atom"]
```

Al iniciar el servidor:

```
export LOG_LEVEL=DEBUG
python main.py
```

Pydantic carga automáticamente y sobrescribe los defaults.

3.5 Beneficios

✓ **Una sola fuente de verdad** para configuración ✓ **Validación automática** de tipos (Pydantic valida que PORT sea int) ✓ **Diferentes configs por entorno** (dev/staging/prod) ✓ **Documentación integrada** (type hints + docstrings) ✓ **Fácil testing** (puedes mockear settings)

4. SISTEMA DE LOGGING (bots/logger.py)

4.1 Problema Que Resuelve

Antes:

```
# En orchestrator.py
print("✓ Base de datos cargada")
print(f"✗ ERROR: {e}")
```

```
# En main.py
print(f"➡ Petición recibida: {question}")
```

Problemas: - print() va siempre a stdout, difícil de filtrar - Sin niveles (INFO, WARNING, ERROR) - Sin timestamps automáticos - No se puede redirigir a archivo - Mezcla logs de debug con producción

Solución: Logger centralizado con niveles configurables

4.2 Código Completo

```
import logging
import os
```

- logging: Librería estándar de Python para logs
- os: Para leer variables de entorno (LOG_LEVEL)

```
_logger = logging.getLogger("revista_expats_ai")
```

¿Qué hace getLogger()? - Crea o recupera un logger con nombre "revista_expats_ai" - Permite tener múltiples loggers independientes en la app - El nombre ayuda a identificar origen de logs en producción

```
if not _logger.handlers:
```

¿Por qué este check? - Si importamos logger.py múltiples veces, no queremos duplicar handlers - handlers son los

destinos de los logs (consola, archivo, etc.) - Solo configuramos si no hay handlers previos

```
level = os.getenv("LOG_LEVEL", "INFO").upper()
```

Niveles de logging: - DEBUG: Muy verbose, para desarrollo (ej: valores de variables) - INFO: Informativo, eventos normales (ej: “Servidor iniciado”) - WARNING: Advertencias, algo raro pero no crítico - ERROR: Errores, pero la app sigue funcionando - CRITICAL: Errores fatales, la app debe detenerse

Ejemplo:

```
export LOG_LEVEL=DEBUG # Muestra todo
export LOG_LEVEL=ERROR # Solo errores y críticos

_logger.setLevel(getattr(logging, level, logging.INFO))

• getattr(logging, level, logging.INFO):
  ◦ Si level="DEBUG" → retorna logging.DEBUG
  ◦ Si level="INVALID" → retorna logging.INFO (fallback)
• setLevel(): Establece nivel mínimo del logger

handler = logging.StreamHandler()

• Crea un handler que escribe a stdout (consola)
• En producción podrías usar FileHandler() para escribir a archivo

formatter = logging.Formatter(
    fmt="%(asctime)s %(levelname)s %(name)s - %(message)s",
    datefmt="%Y-%m-%d %H:%M:%S",
)
```

Formato de logs: - %(asctime)s: Timestamp (2025-12-19 21:30:45) - %(levelname)s: Nivel (INFO, ERROR, etc.) - %(name)s: Nombre del logger (revista_expats_ai) - %(message)s: El mensaje de log

Ejemplo de output:

```
2025-12-19 21:30:45 INFO revista_expats_ai - Servidor iniciado
2025-12-19 21:30:50 ERROR revista_expats_ai - Error cargando BD: File not found
```

```
handler.setFormatter(formatter)
_logger.addHandler(handler)

• Asocia el formateador al handler
• Añade el handler al logger

logger = _logger

• Exportamos como logger para uso externo
• Uso: from bots.logger import logger
```

4.3 Uso en el Código

En orchestrator.py:

```
from .logger import logger

class Orchestrator:
    def __init__(self):
        try:
            self.advertisers = json.load(f)
            logger.info("Base de datos cargada.") # ← INFO
        except Exception as e:
            logger.error(f"ERROR cargando BD: {e}") # ← ERROR
```

En main.py:

```
from bots.logger import logger

@app.post("/api/query")
def handle_query(request: QueryRequest):
    logger.info(f"Petición: '{request.question}', limit={request.limit}")
    # ...
    logger.error(f"ERROR en /api/query: {e}")
```

4.4 Ventajas

✓ **Filtrado por nivel:** En dev LOG_LEVEL=DEBUG, en prod LOG_LEVEL=WARNING ✓ **Timestamps automáticos:** Útil para debugging y análisis ✓ **Redirección fácil:** Cambiar de consola a archivo sin modificar código ✓ **Integración con herramientas:** Compatible con Sentry, LogDNA, etc. ✓ **Rendimiento:** Logs DEBUG no se evalúan si LOG_LEVEL=INFO

5. UTILIDADES COMPARTIDAS (bots/utils.py)

5.1 Propósito del Módulo

Centralizar funciones reutilizables que se usan en múltiples bots: - Normalización de texto (minúsculas, sin acentos) - Filtrado de anunciantes por keywords - Construcción de key_points (evita duplicación)

5.2 Función normalize()

```
import unicodedata
from typing import List, Dict
from config import settings
```

- unicodedata: Para normalización Unicode (quitar acentos)
- typing: Type hints para claridad
- config: Acceso a configuración centralizada

```
def normalize(s):
    if not s:
        return ""
```

- **Guard clause:** Si s es None o string vacío, retornar ""
- Evita errores downstream

```
s = str(s).strip()
```

- str(s): Convierte a string (por si acaso es int u otro tipo)
- .strip(): Remueve espacios al inicio/fin (" hola " → "hola")

```
s = unicodedata.normalize('NFKD', s)
```

¿Qué es NFKD? - Normalización Unicode: descompone caracteres acentuados - “á” → “a” + acento combinado - Permite remover acentos fácilmente

```
s = ''.join(c for c in s if not unicodedata.combining(c))
```

- **List comprehension:** Itera cada carácter
- unicodedata.combining(c): Retorna True si es acento combinado
- not combining(c): Solo caracteres NO acentos
- Resultado: “José” → “Jose”, “Español” → “Espanol”

```
return s.lower()
```

- Convierte a minúsculas para comparaciones case-insensitive
- “HOLA” → “hola”

Ejemplo completo:

```
normalize(" José García ")
# → "jose garcia"
```

5.3 Función build_key_points()

```
def build_key_points(advertisers: List[Dict], max_items: int = None) -> List[Dict]:
    """
    Extrae puntos clave (nombre, descripción, beneficios) de los primeros N anunciantes.
    Centraliza la lógica que antes se repetía en cada bot.

    Args:
        advertisers: Lista de anunciantes
        max_items: Número máximo de puntos clave (default: settings.MAX_KEY_POINTS)

    Returns:
        Lista de dicts con {nombre, descripcion, beneficios}
    """
```

¿Por qué existe?

ANTES (en cada bot):

```
# bot_legal.py
key_points = []
for advertiser in selected_advertisers[:2]:
    point = {
        "nombre": advertiser.get("nombre"),
        "descripcion": advertiser.get("descripcion"),
        "beneficios": advertiser.get("beneficios", [])
    }
    key_points.append(point)
```

```
# bot_accommodation.py
key_points = [] # ← MISMO CÓDIGO REPETIDO
for advertiser in selected_advertisers[:2]:
    # ... idéntico ...
```

DESPUÉS (todos los bots):

```
from .utils import build_key_points
```

```
key_points = build_key_points(selected_advertisers) # ← UNA LÍNEA
```

Código de la función:

```
if max_items is None:
    max_items = settings.MAX_KEY_POINTS
```

- Si no se especifica max_items, usar valor de configuración (default 2)
- Permite sobrescribir: build_key_points(ads, max_items=5)

```
key_points = []
for advertiser in advertisers[:max_items]:
```

- advertisers[:max_items]: Slicing para tomar solo primeros N
- Ejemplo: [:2] → primeros 2 elementos

```
    point = {
        "nombre": advertiser.get("nombre"),
        "descripcion": advertiser.get("descripcion"),
        "beneficios": advertiser.get("beneficios", [])
    }
```

- .get(key, default): Método seguro de dict
- Si key no existe → retorna default ([] para beneficios)
- Evita KeyError

```
    key_points.append(point)
```

```
return key_points
```

- Construye lista de puntos clave y retorna

Ejemplo:

```
advertisers = [
    {"nombre": "Abogado A", "descripcion": "Experto NIE", "beneficios": ["24/7"]},
    {"nombre": "Abogado B", "descripcion": "Visas", "beneficios": []},
    {"nombre": "Abogado C", "descripcion": "Contratos", "beneficios": ["Online"]}
]
```

```
key_points = build_key_points(advertisers, max_items=2)
```

```
# Resultado:
```

```
# [
#   {"nombre": "Abogado A", "descripcion": "Experto NIE", "beneficios": ["24/7"]},
#   {"nombre": "Abogado B", "descripcion": "Visas", "beneficios": []}
# ]
```

5.4 Función filter_advertisers_by_keywords()

```
def filter_advertisers_by_keywords(pregunta, anunciantes, keywords, search_fields=['nombre', 'descripcion', 'perfil',
                                         'ubicacion']):
```

```
    """
```

```
    Función reutilizable para filtrar una lista de anunciantes.
```

```
    - Prioriza los anunciantes que coinciden con las palabras clave.
    - Si no hay coincidencias, devuelve el resto.
```

```
    """
```

¿Qué hace esta función? 1. Normaliza la pregunta 2. Para cada anunciante, combina campos relevantes en un texto 3. Busca si alguna keyword está presente 4. Divide en dos listas: matching (con keywords) y others (sin keywords) 5. Ordena cada lista priorizando sponsors 6. Retorna primero los matching, luego others si no hay matching

Código paso a paso:

```
if not anunciantes:
    return []
```

- Guard clause: Si lista vacía → retornar lista vacía
- Evita iteraciones innecesarias

```
pregunta_norm = normalize(pregunta or "")
```


- Normaliza la pregunta del usuario
- pregunta or "": Si pregunta es None → usar ""

```
matching, others = [], []
for a in anunciantes:
```

- matching: Anunciantes que coinciden con keywords
- others: Anunciantes que NO coinciden
- Iteramos cada anunciante

```
combined_text = ' '.join([str(a.get(k, '')) for k in search_fields])
```

Explicación detallada: - search_fields: Por default ['nombre', 'descripcion', 'perfil', 'ubicacion'] - Para cada field, obtiene valor del dict: a.get('nombre', '') - str(): Convierte a string por seguridad - ' '.join(): Une con espacios

Ejemplo:

```
a = {
    "nombre": "Clínica Dental ABC",
    "descripcion": "Dentista especializado en implantes",
    "ubicacion": "Eixample, Barcelona"
}
search_fields = ['nombre', 'descripcion', 'ubicacion']
combined_text = "Clínica Dental ABC Dentista especializado en implantes Eixample, Barcelona"

combined_norm = normalize(combined_text)
```

- Normaliza el texto combinado
- “Clínica Dental ABC...” → “clinica dental abc dentista...”

```
found = any(kw in pregunta_norm or kw in combined_norm for kw in keywords)
```

Explicación de any(): - any(iterable): Retorna True si al menos un elemento es True - Para cada keyword, verifica: - ¿Está en pregunta_norm? (ej: “dentista” en “necesito un dentista”) - ¿Está en combined_norm? (ej: “dentista” en campos del anunciante) - Si alguna keyword coincide → found = True

Ejemplo:

```
keywords = ["dentista", "dental", "implante"]
pregunta_norm = "necesito un dentista"
combined_norm = "clinica dental abc dentista especializado implantes..."
```

```
# Checking:
# "dentista" in "necesito un dentista" → True ✓
# Result: found = True
```

```
(matching if found else others).append(a)
```

- **Ternary in Python:** (A if condition else B).method()
- Si found=True → append a matching
- Si found=False → append a others

```
def sponsor_key(item):
    flag = item.get('es_anunciante') or item.get('sponsored') or item.get('featured')
    return 1 if flag else 0
```

Función helper para sorting: - Busca si anunciante tiene flag de sponsor/featured - Si tiene cualquiera de los flags → retorna 1 - Si no tiene ninguno → retorna 0 - Se usa para ordenar (1 viene antes que 0 con reverse=True)

```
if matching:
    matching.sort(key=sponsor_key, reverse=True)
    return matching
```

- Si hay anunciantes matching:
 - Los ordena por sponsor_key descendente
 - Sponsors (key=1) primero, normales (key=0) después
 - Retorna solo los matching

```
else:
    others.sort(key=sponsor_key, reverse=True)
    return others
```

- Si NO hay matching:
 - Ordena others por sponsor
 - Retorna todos (mejor algo que nada)

Ejemplo completo:

```
pregunta = "Necesito un dentista urgente"
anunciantes = [
    {"nombre": "Hotel BCN", "descripcion": "...", "es_anunciante": False},
```

```

{"nombre": "Clínica Dental", "descripcion": "implantes", "es_anunciante": True},
{"nombre": "Dentista López", "descripcion": "urgencias", "es_anunciante": False},
]

keywords = ["dentista", "dental", "clinica"]

result = filter_advertisers_by_keywords(pregunta, anunciantes, keywords)
# → [
#     {"nombre": "Clínica Dental", ...}, # ← Sponsor primero
#     {"nombre": "Dentista López", ...}  # ← Match pero no sponsor
# ]
# Hotel BCN NO está en resultado (no match)

```

5.5 Beneficios de utils.py

✓ **DRY (Don't Repeat Yourself):** Código compartido en un solo lugar ✓ **Mantenibilidad:** Cambios en una función afectan a todos los bots ✓ **Testing:** Fácil testear funciones aisladas ✓ **Claridad:** Los bots quedan más simples y enfocados

[CONTINÚA EN PARTE 2 - El reporte completo tiene más de 15,000 palabras. ¿Quieres que genere el resto en archivos separados o continúo aquí?]

6. GESTOR DE CONTENIDO EDITORIAL (bots/content_manager.py)

6.1 Objetivo

Cargar y buscar guías editoriales (JSON) que están en data/guides/. Estas guías son contenido de la revista (ej: “Guía NIE Completa”, “Sistema de Salud en Barcelona”).

6.2 Código Completo Explicado

```

import json
from pathlib import Path
from typing import List, Dict, Optional

```

- pathlib.Path: Manejo moderno de rutas (mejor que os.path)
- typing: Type hints para documentación

```

class ContentManager:
    def __init__(self):
        self.base_dir = Path(__file__).resolve().parent.parent

```

¿Qué hace esto? - `__file__`: Ruta del archivo actual (content_manager.py) - `.resolve()`: Ruta absoluta (resuelve symlinks) - `.parent`: Sube un nivel (de bots/ a raíz del proyecto) - `.parent` otra vez: Desde raíz

Resultado: Si `content_manager.py` está en `/proyecto/bots/content_manager.py`: - `base_dir` = `/proyecto/`

```

self.guides_dir = self.base_dir / "data" / "guides"
self.articles_dir = self.base_dir / "data" / "articles"

```

- `/` operator de Path: Concatena rutas de forma segura
- `self.guides_dir` = `/proyecto/data/guides/`

```

self.guides = self._load_guides()
print(f"✓ Contenido editorial cargado: {len(self.guides)} guías disponibles")

```

- Carga todas las guías al inicializar
- Print feedback (debería ser logger, pero esto se escribió antes)

```

def _load_guides(self) -> List[Dict]:
    """Carga todas las guías disponibles"""
    guides = []
    if self.guides_dir.exists():

```

- `_load_guides`: Método privado (prefijo `_`)
- Verifica si directorio existe antes de iterar

```

    for guide_file in self.guides_dir.glob("*.json"):

```

- `.glob("*.json")`: Encuentra todos los archivos `.json`
- Ejemplo: `nie_completa.json`, `sistema_salud.json`

```

    try:
        with open(guide_file, 'r', encoding='utf-8') as f:
            guide = json.load(f)
            guide['tipo'] = 'guia'
            guides.append(guide)
    except Exception as e:

```

```
print(f"⚠ Error cargando {guide_file}: {e}")
```

- Context manager (with): Auto-cierra archivo
- `json.load(f)`: Parsea JSON a dict de Python
- Añade campo `tipo='guia'` para identificación
- Try/except: Si un archivo está corrupto, continúa con los demás

```
return guides
```

6.3 Función `search_guides()`

```
def search_guides(self, keywords: List[str], categoria: str = None) -> List[Dict]:  
    """  
    Busca guías relevantes basándose en keywords y categoría.  
  
    Args:  
        keywords: Lista de palabras clave para buscar  
        categoria: Categoría específica (Healthcare, Legal, etc.)  
  
    Returns:  
        Lista de guías relevantes ordenadas por relevancia  
    """
```

Sistema de scoring:

```
relevant_guides = []
```

```
for guide in self.guides:  
    score = 0
```

- Inicia score en 0 para cada guía
- Irá acumulando puntos

```
# Coincidencia de categoría (peso 3)  
if categoria and guide.get('categoria') == categoria:  
    score += 3
```

- Si la guía es de la categoría correcta → +3 puntos
- Ejemplo: Busco “Legal”, guía es “Legal” → score=3

```
# Coincidencia en keywords de la guía (peso 2)  
guide_keywords = [k.lower() for k in guide.get('keywords', [])]  
for keyword in keywords:  
    if any(keyword.lower() in gk for gk in guide_keywords):  
        score += 2
```

- Cada guía tiene un array de keywords
- Si keyword del usuario coincide con keyword de guía → +2
- `any()`: Al menos una coincidencia

```
# Coincidencia en título (peso 1)  
titulo = guide.get('titulo', '').lower()  
for keyword in keywords:  
    if keyword.lower() in titulo:  
        score += 1
```

- Si keyword está en el título → +1
- Peso menor porque título puede tener palabras genéricas

```
if score > 0:  
    guide_copy = guide.copy()  
    guide_copy['relevancia'] = score  
    relevant_guides.append(guide_copy)
```

- Solo añade guías con `score > 0`
- Copia la guía y añade campo `relevancia`

```
# Ordenar por relevancia  
relevant_guides.sort(key=lambda x: x['relevancia'], reverse=True)  
return relevant_guides
```

- Ordena de mayor a menor relevancia
- Las más relevantes primero

Ejemplo:

```
keywords = ["nie", "residencia", "visa"]  
categoria = "Legal and Financial"
```

```
guides = [  
    {"titulo": "Guía NIE Completa", "categoria": "Legal and Financial", "keywords": ["nie", "extranjeria"]},
```

```

    {"titulo": "Trabajar en Barcelona", "categoria": "Work", "keywords": ["empleo", "visa"]},
]

result = content_manager.search_guides(keywords, categoria)
# Guía 1: cat match(+3) + kw "nie"(+2) + título "nie"(+1) = 6
# Guía 2: kw "visa"(+2) = 2
# Orden: [Guía 1, Guía 2]

```

6.4 Función get_guide_summary()

```

def get_guide_summary(self, guide: Dict) -> Dict:
    """
    Devuelve un resumen corto de la guía para mostrar en el chat.
    """
    return {
        "tipo": "guia_revista",
        "titulo": guide.get('titulo'),
        "resumen": guide.get('resumen'),
        "slug": guide.get('slug'),
        "url": f"/revista/guias/{guide.get('slug')}",
        "categoria": guide.get('categoria')
    }

```

- Extrae solo campos relevantes para el frontend
- Construye URL dinámica usando slug
- Ejemplo: slug="nie-completa" → url="/revista/guias/nie-completa"

7. GESTOR DE FEEDS RSS (bots/rss_manager.py)

7.1 Objetivo

Parsear los feeds RSS/Atom de Barcelona Metropolitan, almacenar artículos en caché local y proveer búsqueda por palabras clave y por categoría.

7.2 Código Explicado Línea a Línea (fragmentos clave)

```

"""
RSS Feed Manager: parsea feeds de la revista y cachea artículos localmente.
Actualiza cada 6-12 horas en background.
"""

```

- Docstring que describe el propósito del módulo y la frecuencia de actualización.

```

import json
import feedparser
from pathlib import Path
from datetime import datetime
from typing import List, Dict, Optional
from .logger import logger

```

- feedparser: librería para parsear RSS/Atom.
- Path: manejo de rutas.
- datetime: timestamps para synced_at.
- logger: logs estructurados.

```

class RSSManager:
    def __init__(self):
        self.base_dir = Path(__file__).resolve().parent.parent
        self.cache_dir = self.base_dir / "data" / "cache"
        self.cache_dir.mkdir(parents=True, exist_ok=True)
        self.articles_cache = self.cache_dir / "articles.json"

```

- Calcula ruta base y asegura que data/cache exista.
- Define archivo articles.json para caché.

```

        self.feed_urls = [
            "https://www.barcelona-metropolitan.com/directory/index.rss",
        ]

```

- Lista de feeds a sincronizar. Se pueden añadir más feeds.

```

        self.articles = self.load_cache()
        logger.info(f"RSS Manager inicializado. {len(self.articles)} artículos en caché.")

```

- Carga caché al iniciar y reporta cantidad en logs.

```

def load_cache(self) -> List[Dict]:
    if self.articles_cache.exists():
        try:

```

```

        with open(self.articles_cache, 'r', encoding='utf-8') as f:
            return json.load(f)
    except Exception as e:
        logger.warning(f"Error cargando caché: {e}")
    return []

```

- Lectura segura del archivo de caché con manejo de errores.

```

def save_cache(self):
    try:
        with open(self.articles_cache, 'w', encoding='utf-8') as f:
            json.dump(self.articles, f, ensure_ascii=False, indent=2)
    except Exception as e:
        logger.error(f"Error guardando caché: {e}")

```

- Persistencia de artículos en disco en formato JSON legible.

```

def sync_feeds(self) -> int:
    new_count = 0
    existing_urls = {a.get('url') for a in self.articles}
    for feed_url in self.feed_urls:
        try:
            logger.info(f"Parseando feed: {feed_url}")
            feed = feedparser.parse(feed_url)
            if not feed.entries:
                logger.warning(f"Feed vacío o no accesible: {feed_url}")
                continue
            entries_count = 0
            for entry in feed.entries[:50]:
                article = {
                    "url": entry.get('link', '') or entry.get('id', ''),
                    "title": entry.get('title', 'Sin título'),
                    "description": entry.get('summary', entry.get('description', ''))[:500],
                    "published": entry.get('published', entry.get('updated', '')),
                    "categories": [t.get('term') if isinstance(t, dict) else str(t) for t in entry.get('tags', [])],
                    "source": feed.feed.get('title', 'Barcelona Metropolitan'),
                    "synced_at": datetime.utcnow().isoformat()
                }
                if article['url'] and article['url'] not in existing_urls:
                    self.articles.append(article)
                    existing_urls.add(article['url'])
                    new_count += 1
                    entries_count += 1
            logger.info(f"Feed '{feed.feed.get('title', 'Unknown')}': {entries_count} nuevas entradas parseadas.")
        except Exception as e:
            logger.error(f"Error parseando {feed_url}: {e}")
    if len(self.articles) > 1000:
        self.articles = sorted(self.articles, key=lambda x: x.get('synced_at', ''), reverse=True)[:1000]
    self.save_cache()
    logger.info(f"Sync completado: {new_count} artículos nuevos. Total: {len(self.articles)}")
    return new_count

```

- Recorre todos los feeds, parsea entradas y evita duplicados por URL.
- Limita a 50 por feed y máx. 1000 en caché.
- Guarda caché y retorna número de nuevos artículos.

```

def search_articles(self, keywords: List[str], limit: int = 5) -> List[Dict]:
    if not keywords or not self.articles:
        return []
    keyword_set = {kw.lower() for kw in keywords if len(kw) > 2}
    scored = []
    for article in self.articles:
        text = f"{article.get('title', '')} {article.get('description', '')} " \
            f"{ ' '.join([t.get('term', '') if isinstance(t, dict) else str(t) for t in article.get('categories', [])]) }".lower()
        score = sum(1 for kw in keyword_set if kw in text)
        if score > 0:
            scored.append((score, article))
    scored.sort(key=lambda x: x[0], reverse=True)
    return [article for _, article in scored[:limit]]

```

- Búsqueda por keywords en título, descripción y tags con scoring simple.

```

def get_articles_by_category(self, category: str, limit: int = 3) -> List[Dict]:
    category_keywords = {
        "Legal and Financial": ["legal", "visa", "nie", "impuesto", "contrato", "bank", "immigration"],
        "Healthcare": ["salud", "doctor", "hospital", "dentista", "health", "medical", "clinic"],
        "Education": ["escuela", "colegio", "university", "idioma", "course", "school", "education"],
        "Accommodation": ["alojamiento", "hotel", "apartamento", "vivienda", "housing", "apartment", "rent"],
        "Restaurants": ["restaurante", "comida", "food", "restaurant", "dining", "cuisine"],
        "Arts and Culture": ["arte", "cultura", "museo", "gallery", "culture", "exhibition"],
        "Work and Networking": ["trabajo", "empleo", "job", "networking", "business", "work"],
    }

```

```
keywords = category_keywords.get(category, [])
return self.search_articles(keywords, limit)
```

- Mapeo manual de categorías → keywords; delega a search_articles.

7.3 Errores Comunes y Soluciones

- Feed vacío/no accesible: revisar URL y conexión; ver logs WARNING Feed vacío.
- Duplicados: se evita por URL; si un feed usa id distinto, se toma link.
- Crecimiento infinito: límite 1000 artículos; ajustar en config.py si necesario.

8. ORQUESTADOR PRINCIPAL (bots/orchestrator.py)

8.1 Responsabilidades

- Cargar base de datos de anunciantes.
- Clasificar intención con embeddings y fallback de keywords.
- Enrutar a bot especializado.
- Enriquecer con guías y artículos.
- Aplicar paginación limit/offset y devolver has_more/next_offset.

8.2 Código Explicado (puntos clave)

```
from sentence_transformers import SentenceTransformer, util
from .rss_manager import get_rss_manager
from config import settings
```

- Importa modelo de embeddings, RSS Manager y configuración.

```
class Orchestrator:
    def __init__(self):
        base_dir = Path(__file__).resolve().parent.parent
        data_path = base_dir / "data" / "anunciantes.json"
        with open(str(data_path), 'r', encoding='utf-8') as f:
            self.advertisers = json.load(f)
        self.content_manager = ContentManager()
        self.rss_manager = get_rss_manager()
        self.model = SentenceTransformer('paraphrase-multilingual-MiniLM-L12-v2')
```

- Carga anunciantes y servicios auxiliares.
- Inicia modelo multilingüe para embeddings.

```
self.category_patterns = {"es": { ... }, "en": { ... }}
```

- Palabras clave por idioma y categoría para fallback y tips.

```
self.bots_map = {
    "Accommodation": acc_responder,
    "Legal and Financial": leg_responder,
    ...,
    "Restaurants": generic_responder,
}
```

- Mapa categoría → función responder_consulta del bot adecuado; genérico para categorías simples.

```
self.category_info = []
for category in all_categories:
    description = f"Servicios sobre {category.lower()}: " + ", ".join(keywords_es + keywords_en)
    self.category_info.append({
        "name": category,
        "description": description,
        "embedding": self.model.encode(description, convert_to_tensor=True)
    })
```

- Precalcula embeddings por categoría para velocidad de clasificación.

```
def classify_intent(self, question, language="en"):
    qn = normalize(question)
    question_embedding = self.model.encode(question, convert_to_tensor=True)
    import torch
    category_embeddings = torch.stack([cat["embedding"] for cat in self.category_info])
    cos_scores = util.cos_sim(question_embedding, category_embeddings)[0]
    top_result = int(cos_scores.argmax().item())
    best_score = float(cos_scores[top_result].item())
    best_match_category = self.category_info[top_result]["name"]
```

- Convierte pregunta a embedding, calcula similitud coseno y toma la categoría con mayor score.

```
for category, businesses in self.advertisers.items():
```

```

for business in businesses:
    name = normalize(business.get('nombre', ''))
    if name and name in qn:
        return category, 0.9, business

```

- Override por nombre explícito de negocio: prioridad absoluta si el usuario nombra un anunciante.

```

kw_map = self.category_patterns.get(language, {})
best_kw_cat = None; best_hits = 0
for cat, kws in kw_map.items():
    hits = sum(1 for kw in kws if kw in qn)
    if hits > best_hits:
        best_hits, best_kw_cat = hits, cat
if best_kw_cat and best_hits > 0:
    return best_kw_cat, max(0.25, min(0.9, 0.15 * best_hits + 0.25)), None

```

- Fallback por keywords: calcula “confianza” basada en hits usando parámetros de config.py (modelo matemático sencillo: base + multiplicador).

```

if best_score > 0.2:
    return best_match_category, best_score, None
else:
    return "Desconocida", best_score, None

```

- Umbral de confianza: si la similitud es baja, marca como desconocido.

```

def process_query(self, question, language="en", limit: int = 3, offset: int = 0):
    categoria, confidence, advertiser = self.classify_intent(question, language)
    resultados = self.advertisers.get(categoria, [])
    if advertiser and advertiser not in resultados:
        resultados.insert(0, advertiser)
    keywords = [word.lower() for word in question.split() if len(word) > 3]
    guias_relevantes = self.content_manager.search_guides(keywords, categoria)
    articulos_revista = self.rss_manager.get_articles_by_category(categoria, limit=3)
    bot_response = self.bots_map[categoria](question, resultados, language=lang)
    all_items = bot_response.get("json_data", [])
    total = len(all_items)
    sliced = all_items[offset:offset + limit] if (limit not in (None, 0)) else all_items[offset:]
    has_more = (offset + (limit or 0)) < total if limit not in (None, 0) else False
    next_offset = (offset + (limit or 0)) if has_more else None

```

- Enriquecimiento y paginación: slicing y cálculo de has_more/next_offset.

8.3 Errores y Soluciones

- Modelo no instalado: ejecutar `pip install sentence-transformers torch`.
- anunciantes.json faltante: verificar ruta `data/anunciantes.json`.
- Clasificación confusa: ajustar `CONFIDENCE_THRESHOLD` en `config.py`.

9. BOTS ESPECIALIZADOS

Cada bot expone `responder_consulta(pregunta, anunciantes, language)` y retorna `{ key_points, json_data }`. La lógica común se apoya en utilidades compartidas.

9.1 Patrón Común

- Definir keywords por categoría.
- Usar `filter_advertisers_by_keywords()` para priorizar sponsors con match.
- Construir `key_points` con `build_key_points()`.
- Retornar lista completa; el orquestador aplica paginación.

9.2 Ejemplos

Bot Legal:

```

from .utils import filter_advertisers_by_keywords, build_key_points
def responder_consulta(pregunta, anunciantes, language="en"):
    keywords = ["abogado", "legal", "impuestos", "nie", "visa", "bank", ...]
    selected = filter_advertisers_by_keywords(pregunta, anunciantes, keywords)
    key_points = build_key_points(selected)
    return {"key_points": key_points, "json_data": selected}

```

Bot Healthcare (con integración Maps):

```

from .maps_integration import search_healthcare_barcelona
selected = filter_advertisers_by_keywords(pregunta, anunciantes, keywords)
for advertiser in selected:
    advertiser["es_anunciante"] = True

```

```
if len(selected) < 3:
    search_term = "hospital" # ajustado según la pregunta
    maps_results = search_healthcare_barcelona(search_term, limit=5)
    selected.extend(maps_results)
return {"key_points": build_key_points(selected), "json_data": selected}
```

Bot Accommodation:

```
selected = filter_advertisers_by_keywords(pregunta, anunciantes, keywords)
return {"key_points": build_key_points(selected), "json_data": selected}
```

9.3 Soluciones a Problemas Comunes

- Demasiados resultados irrelevantes: ajustar keywords y search_fields en utils.filter_advertisers_by_keywords.
- Falta de beneficios: build_key_points() usa [] por defecto; completar datos en anunciantes.json.

10. BACKEND API (main.py)

10.1 Setup

- FastAPI con lifespan para scheduler.
- BackgroundScheduler de APScheduler para sync RSS cada 6 horas.
- CORS abierto en desarrollo; restringir en producción.

10.2 Modelos

```
class QueryRequest(BaseModel):
    pregunta: str = None
    question: str = None
    language: str = "es"
    session_id: str = None
    limit: int | None = 5
    offset: int = 0
    def get_question(self):
        return self.pregunta or self.question or ""
```

- Compatibilidad con pregunta y question.
- Paginación: limit/offset.

10.3 Endpoints

- GET /api/health: health check.
- GET /api/categories: categorías disponibles.
- GET /api/sync-rss: sincronización manual.
- POST /api/query: consulta principal, loguea, enruta y responde.
- POST /api/analytics: guarda eventos en data/analytics/events.jsonl.

10.4 Errores y Soluciones

- 500 en /api/query: revisar logs ERROR en /api/query; verificar que Orchestrator se inicializó.
- CORS bloquea requests externos: configurar allow_origins con dominios permitidos.

11. FRONTEND (HTML/CSS/JS)

11.1 index.html

- Estructura con secciones: Header, Hero, Artículos, Guías, Servicios, Anunciantes, Newsletter, Footer.
- Chat flotante (widget-like) integrado al final.
- Carga script.js y styles.css.

11.2 styles.css

- Variables CSS, diseño responsivo, componentes estilizados (cards, carrusel, chat).
- Optimizado para lectura y acciones (CTAs destacadas).

11.3 script.js (puntos clave)

- sendQuery(): envía POST con {question, language, limit, offset}; maneja errores con diagnóstico en consola.
- updateBotMessage(): renderiza respuesta, guías, artículos RSS, resultados, botón “Mostrar más”, y tracking de clics.
- Paginación: mantiene lastQuery y nextOffset para cargar más resultados.
- FAQ desplegable: acordeón interactivo por anunciante.
- Quick actions: botones predefinidos para categorías frecuentes.

12. WIDGET EMBEBIBLE (widget.js / embed.js)

12.1 embed.js

- Carga widget.css y widget.js desde el dominio de la API.
- Inicializa el widget con ExpatAssistantWidget(config).

12.2 widget.js

- Clase ExpatAssistantWidget con configuración (API URL, color, sugerencias).
- Métodos: init(), createWidget(), attachEventListeners(), sendMessage(), addAdvertisers(), addGuides(), trackEvent().
- Renderiza mensajes, muestra typing indicator y envía requests a /api/query.
- Integra tracking (Google Analytics, Meta Pixel y backend propio).

12.3 Consideraciones

- Personalizable vía window.ExpatAssistantConfig.
 - Se puede montar en cualquier sitio externo sin conflictos.
-

13. EVOLUCIÓN Y MEJORAS

- Integración RSS con caché y scheduler.
 - Paginación limit/offset + botón “Mostrar más” en frontend.
 - Configuración centralizada con config.py (Pydantic BaseSettings).
 - Logging estructurado con bots/logger.py.
 - DRY: build_key_points() y filter_advertisers_by_keywords() en utils.py.
 - Limpieza de dependencias (Flask removido, FastAPI activo).
 - Guías editoriales y tips por categoría.
-

14. TROUBLESHOOTING

- “El feed no sincroniza”: probar GET /api/sync-rss; verificar conectividad; revisar logs.
 - “Error de clasificación”: bajar/ajustar CONFIDENCE_THRESHOLD en config.py.
 - “CORS bloqueado”: configurar allow_origins en main.py con dominios reales.
 - “Sin anunciantes”: comprobar data/anunciantes.json y formato de campos; ajustar search_fields.
-

15. CONCLUSIONES

- Arquitectura modular, escalable y mantenible.
 - Experiencia de usuario rica: recomendaciones + contenido editorial + paginación.
 - Preparado para producción con logging, config central y scheduler.
-

16. EXPORTAR A PDF

Opciones para generar el PDF desde este reporte:

- Usando pandoc (recomendado):
 - Instalar: sudo apt-get install pandoc wkhtmltopdf (opcional para PDF via HTML).
 - Comando: pandoc REPORTE_PROYECTO_COMPLETO.md -o REPORTE_Revista_Expats_AI.pdf.
- Usando wkhtmltopdf (si prefieres render HTML):
 - wkhtmltopdf REPORTE_PROYECTO_COMPLETO.md REPORTE_Revista_Expats_AI.pdf (requiere convertir Markdown a HTML primero: pandoc -s REPORTE_PROYECTO_COMPLETO.md -o reporte.html y luego wkhtmltopdf reporte.html reporte.pdf).

Sugerencia: incluye cabecera/portada con --metadata en pandoc y estilo CSS para una salida profesional.

17. ANEXO: CÓDIGO CLAVE INCLUIDO

Para referencia rápida, se han explicado y mostrado los fragmentos críticos en las secciones anteriores:

- Configuración central: config.py.
- Logger: bots/logger.py.
- Utilidades: bots/utils.py.
- Gestor RSS: bots/rss_manager.py.
- Orquestador: bots/orchestrator.py.
- Bots (Legal, Healthcare, Accommodation).
- Backend FastAPI: main.py.

- Frontend: frontend/index.html, frontend/script.js, frontend/styles.css.
- Widget: widget/embed.js, widget/widget.js, widget/widget.css.

Si deseas añadir un “Anexo B” con el listado completo de todos los archivos del repositorio (contenido íntegro), puedo incorporarlo automáticamente en este documento antes de exportar a PDF.